

Langchain & Groq: Xây Dựng Ứng Dụng AI Thực Tế

Khám phá hai công cụ mạnh mẽ để xây dựng ứng dụng AI dựa trên mô hình ngôn ngữ lớn — từ lý thuyết nền tảng đến thực hành với **các dự án thực tế**. Buổi học này sẽ giúp các bạn tự tin tạo chatbot, tóm tắt văn bản và hệ thống Q&A thông minh.




Nội Dung Thực hành & Mục Tiêu Buổi Học

Nội dung thực hành

- Hệ thống AI Tóm tắt nội dung YouTube
- Xây Chatbot AI sử dụng Groq API
- **Conversation QA chatbot** — Hỏi & Đáp
- AI chatbot text summarization — Tóm tắt văn bản dài

Mục tiêu sau buổi học


- **Hiểu lý thuyết**
Nền tảng LLM và framework
- **Áp dụng ngay**
Chatbot, Q&A, tóm tắt



LLM & Nhu Cầu Về Framework


LLM là gì?

Large Language Models (LLM) như **GPT**, **Llama**, **Gemma** là các mô hình ngôn ngữ được huấn luyện trên lượng văn bản khổng lồ. Chúng rất giỏi tạo và hiểu ngôn ngữ tự nhiên — nhưng có một giới hạn lớn.



Vấn đề cốt lõi

LLM hoạt động **cô lập** — chúng chỉ nhận đầu vào văn bản và trả về văn bản. Chúng không tự kết nối với database, không nhớ lịch sử hội thoại, không tải dữ liệu từ YouTube hay các API bên ngoài. Đây chính là lý do cần một **framework tích hợp** như Langchain.



Mục lục buổi học



Mở Đầu

Tổng quan LLM và nhu cầu framework



Langchain

Từ cơ bản đến ứng dụng thực tế



Groq

Nền tảng tốc độ cao, tích hợp AI



Kết Thúc

Tóm tắt tổng thể và Q&A thảo luận

Langchain Là Gì?

Langchain là framework mã nguồn mở viết bằng Python, được thiết kế chuyên biệt để xây dựng ứng dụng dựa trên LLM. Thay vì gọi LLM đơn thuần qua API, Langchain cho phép bạn **kết nối, tổ chức và tự động hoá** toàn bộ quy trình xử lý ngôn ngữ.

Trong các dự án thực tế, **Langchain** được dùng để tạo **chains xử lý**, quản lý lịch sử chat, tích hợp dữ liệu bên ngoài



Chains

Kết nối các bước xử lý



Memory

Lưu lịch sử hội thoại



Retrieval

Tìm kiếm dữ liệu thông minh

Lý Do Ra Đời Của Langchain


Bối cảnh ra đời

Langchain được tạo ra vào **năm 2022** bởi **Harrison Chase**, một kỹ sư AI có tầm nhìn về việc đơn giản hoá phát triển ứng dụng thông minh. Đây là thời điểm bùng nổ của các LLM như GPT-3 và ChatGPT, nhưng việc tích hợp chúng vào sản phẩm thực tế vẫn còn rất phức tạp.



Nhu cầu cấp thiết


Trước **Langchain**, các nhà phát triển phải tự xây dựng toàn bộ logic tích hợp — từ quản lý prompt, kết nối dữ liệu đến xử lý output. **Langchain** ra đời để **chuẩn hoá và đơn giản hoá** quy trình này, biến ý tưởng AI từ **proof-of-concept** trở thành hệ thống hoàn chỉnh có thể triển khai thực tế.



Vấn Đề Của LLM

Hoạt động cô lập

LLM chỉ xử lý văn bản đầu vào và trả về văn bản đầu ra. Chúng không thể tự động truy cập cơ sở dữ liệu, file hệ thống, hay API bên ngoài mà không có code tích hợp thủ công.



Phức tạp khi tích hợp

Ví dụ trong dự án **Youtube Text Summarization**, nếu không có Langchain, việc tải transcript YouTube, chia nhỏ văn bản, gọi LLM và tổng hợp kết quả sẽ đòi hỏi hàng trăm dòng code dễ lỗi và khó bảo trì.

Không có bộ nhớ

Mỗi lần gọi API là một phiên độc lập — LLM không nhớ cuộc trò chuyện trước. Để tạo chatbot nhớ lịch sử, lập trình viên phải tự quản lý và gửi lại toàn bộ context mỗi lần.

Tại Sao Cần Học Langchain?

Lợi ích thiết thực

Langchain mở ra cánh cửa xây dựng ứng dụng AI thực tế mà **không cần kiến thức Machine Learning sâu**. Đây là kỹ năng đang được thị trường lao động sẵn đón trong thời đại AI bùng nổ.



Xây app nhanh

Từ ý tưởng đến prototype chỉ trong vài giờ



Cơ hội nghề nghiệp

Kỹ năng được doanh nghiệp ưu tiên tuyển dụng




Không bị giới hạn

Tạo chatbot nhớ lịch sử, RAG, agents phức tạp



Langchain Giải Quyết Vấn Đề Như Thế Nào?

Langchain cung cấp **bộ mô-đun sẵn có** để kết nối LLM với công cụ bên ngoài, biến một mô hình ngôn ngữ đơn thuần thành một hệ thống AI thông minh, hoàn chỉnh và có thể mở rộng.



Ví dụ cụ thể: Trong dự án **Text Summarization**, Langchain tự động chia văn bản dài thành các chunks, gửi từng chunk qua chain refine, và tổng hợp kết quả — thay thế hoàn toàn quy trình code thủ công phức tạp.


Nguyên Tắc Cốt Lõi: Chaining

Chaining là gì?

Chaining là nguyên tắc **kết nối tuần tự** các thành phần xử lý, sao cho đầu ra của bước trước trở thành đầu vào của bước sau. Đây là khái niệm cốt lõi nhất trong Langchain.

Cú pháp đơn giản:

```
chain = prompt | llm | output_parser
```



01

Prompt Template

Định dạng câu hỏi với biến động

02

LLM Processing

Mô hình xử lý và sinh câu trả lời

03

Output Parser

Định dạng kết quả theo yêu cầu

Components Cơ Bản Trong Langchain

Langchain được xây dựng từ các thành phần mô-đun hoá, cho phép lắp ghép linh hoạt để tạo ra các ứng dụng AI đa dạng.




Prompts

Định dạng câu hỏi động với **ChatPromptTemplate** — giúp tái sử dụng và tùy chỉnh prompt linh hoạt.



Models

Kết nối với LLM như GPT, Groq, hay các mô hình local — thông qua interface thống nhất.



Output Parsers

Chuyển đổi response thô thành cấu trúc dữ liệu Python dễ xử lý (JSON, list, v.v.).




Retrievers

Tìm kiếm thông tin liên quan từ vector store để bổ sung ngữ cảnh cho LLM.

Chains Trong Langchain



Stuff Chain

Nhồi toàn bộ dữ liệu vào một prompt duy nhất và gửi cho LLM. Phù hợp cho văn bản ngắn, đơn giản và nhanh chóng. Hiệu quả khi nội dung vừa đủ với context window của mô hình.



Refine Chain

Xử lý văn bản dài bằng cách **tinh chỉnh dần** — tóm tắt chunk đầu tiên, sau đó cập nhật liên tục với từng chunk tiếp theo. Chất lượng cao hơn nhưng tốn nhiều API calls hơn.





Memory & Lịch Sử Hội Thoại

Tại sao Memory quan trọng? RunnableWithMessageHistory

Mặc định, LLM không nhớ gì giữa các lần gọi. Memory trong Langchain cho phép chatbot trở thành **stateful** — biết bạn là ai, nhớ những gì bạn đã hỏi, và trả lời có ngữ cảnh nhất quán.

Trong dự án **Chatbots Groq**, component này tự động lưu trữ **HumanMessage** và **AIMessage** theo session. Chatbot có thể nhớ tên, nghề nghiệp người dùng và trả lời liên tục mạch lạc trong suốt cuộc hội thoại.



Agents Trong Langchain

Agent là gì?


Agent cho phép **LLM tự quyết định** hành động cần thực hiện — thay vì chạy theo chuỗi cố định, nó phân tích tình huống và chọn tool phù hợp để đạt mục tiêu.

Ví dụ: Tìm kiếm web → Tính toán → Trả kết quả

Lưu ý trong context này


Trong các notebook thực hành của buổi học, chúng ta chủ yếu sử dụng **chains đơn giản** thay vì agents. Lý do: chains có thể dự đoán được, dễ debug và phù hợp hơn cho các tác vụ xác định như tóm tắt hay Q&A.

Agents phù hợp cho các hệ thống phức tạp hơn khi cần LLM tự động hoá nhiều bước quyết định — đây là bước tiếp theo sau khi nắm vững chains.



Quy Trình Hoạt Động Của Langchain

Từ dữ liệu thô đến output hữu ích — đây là luồng xử lý hoàn chỉnh được minh họa:



Mỗi bước trong quy trình được Langchain xử lý qua các mô-đun sẵn có, giúp code gọn gàng, dễ bảo trì và có thể tái sử dụng cho nhiều loại ứng dụng AI khác nhau.

Ứng Dụng Thực Tế: Chatbot Thông Minh

Chatbot hỗ trợ khách hàng

Chúng ta xây dựng được chatbot có khả năng nhớ ngữ cảnh hội thoại — không chỉ trả lời câu hỏi một lần mà duy trì cuộc trò chuyện tự nhiên, liên tục.



Nhớ tên & thông tin

"Hi, I'm Krish" → chatbot nhớ và dùng lại



Ứng dụng thực tế

Tư vấn ngân hàng, dịch vụ khách hàng 24/7



Token Trimming

Tự động cắt bớt lịch sử dài để tiết kiệm chi phí



Ứng Dụng Thực Tế: Q&A Trên Tài Liệu

Hệ thống hỏi đáp nội bộ

Conversation Question

Answering, Langchain xây dựng hệ thống cho phép người dùng đặt câu hỏi bằng ngôn ngữ tự nhiên và nhận câu trả lời chính xác từ tài liệu doanh nghiệp.

Quy trình Retrieval Chain

01

Embed tài liệu

Chuyển văn bản thành vector số

02


Retrieve ngữ cảnh

Tìm đoạn liên quan nhất

03

Generate câu trả lời

LLM tổng hợp từ ngữ cảnh tìm được




Ứng Dụng Thực Tế: Tóm Tắt Nội Dung

Tóm tắt video YouTube & bài viết dài

Text Summarization, Langchain xử lý transcript video dài bằng Refine chain — chia nhỏ, tóm tắt từng phần, rồi tinh chỉnh dần thành bản tóm tắt hoàn chỉnh.

Ứng dụng trong giáo dục: Sinh viên có thể nhanh chóng nắm nội dung bài giảng dài mà không cần xem toàn bộ video. Giảng viên tiết kiệm thời gian chuẩn bị tài liệu ôn tập.



📄📌 Hàm chính: `summarize_docs()` trong `app.py` sử dụng `load_summarize_chain` với `chain_type="refine"`

Ứng Dụng Thực Tế: Tích Hợp RAG

Retrieval-Augmented Generation

RAG là kỹ thuật kết hợp khả năng tìm kiếm tài liệu (Retrieval) với sinh nội dung của LLM (Generation). Thay vì dựa hoàn toàn vào kiến thức được train, LLM nhận thêm ngữ cảnh từ dữ liệu riêng của bạn.

Dữ liệu Riêng

FAQ, tài liệu nội bộ, sản phẩm công ty được lưu trong vector store



Retrieve

Tìm đoạn tài liệu liên quan nhất với câu hỏi người dùng qua similarity search



Generate

LLM tổng hợp câu trả lời chính xác, tránh hallucination từ dữ liệu không có thật

Ví Dụ Thực Hành: Intro to Langchain

Prompt Template cơ bản

Notebook này giới thiệu cách tạo chain đơn giản nhất — dịch ngôn ngữ tự động bằng **ChatPromptTemplate**.

Ví dụ thực tế:

Input: "I love programming" Output: "Ich liebe das Programmieren" (German)

Kết cấu chain:

```
chain = prompt | llmchain.invoke({input, language})
```

Điều gì xảy ra bên trong?

- 1 Template nhận biến**
{input} và {language} được điền vào prompt động
- 2 LLM xử lý**
Groq nhận prompt đã điền và sinh câu trả lời
- 3 Kết quả trả về**
AIMessage với nội dung đã dịch, sẵn sàng dùng

Ví Dụ Thực Hành: Chatbots Groq

Xây dựng Chatbot Stateful

Notebook này minh họa đầy đủ vòng đời của một chatbot — từ khởi tạo model Groq, thiết lập memory, đến xử lý trimming khi hội thoại quá dài.

Điểm nổi bật:

RunnableWithMessageHistory tự động quản lý session, cho phép nhiều người dùng chat độc lập với cùng một chatbot instance.

Luồng hội thoại thực tế

Turn 1


Human: "Hi, I'm Krish and I'm a data scientist" → AI chào và xác nhận thông tin

Turn 2


Human: "What's my name?" → AI nhớ: "Your name is Krish" ✓

Turn 3+

Lịch sử được trim khi vượt giới hạn token để tiết kiệm chi phí



Tóm Tắt Phần Langchain



🎯 **Điểm mấu chốt:** Langchain biến LLM đơn thuần thành hệ thống AI hoàn chỉnh — kết nối, nhớ, tìm kiếm và xử lý dữ liệu thực tế một cách tự động và hiệu quả.

Groq Là Gì?

Groq là nền tảng cloud cung cấp API cho phép chạy các LLM phổ biến (Llama 3, Gemma, Mixtral...) với **tốc độ vượt trội** nhờ phần cứng LPU chuyên biệt. Không cần GPU đắt tiền, bạn chỉ cần một API key là có thể bắt đầu.

Trong các notebook thực hành, Groq đóng vai trò **backend LLM** cho Langchain — xử lý mọi yêu cầu sinh text với độ trễ cực thấp.



Tốc độ cao

Phản hồi dưới 100ms



Cloud API

Dễ tích hợp qua REST




Chi phí thấp

Free tier cho thử nghiệm

Vấn Đề Của LLM Trước Groq

Latency cao

Chạy LLM trên GPU thông thường có độ trễ từ 1–10 giây, gây khó chịu cho người dùng khi trò chuyện real-time. Đặc biệt khi tải cao, thời gian chờ có thể kéo dài hơn nhiều.



Chi phí đắt đỏ

GPU cao cấp (A100, H100) rất đắt tiền và tiêu tốn nhiều điện năng. Startups và cá nhân khó tiếp cận, tạo rào cản lớn cho việc thử nghiệm và triển khai ứng dụng AI.



Trải nghiệm kém

Ví dụ cụ thể: trong **thực tế**, nếu tóm tắt một video dài 1 giờ trên GPU thông thường, người dùng có thể phải chờ vài phút trước khi nhận được kết quả — không thể chấp nhận được trong môi trường production.



Tại Sao Cần Học Groq?

Lợi thế cạnh tranh rõ ràng

Trong thị trường AI ngày càng cạnh tranh, **tốc độ phản hồi** và **chi phí vận hành** là hai yếu tố quyết định thành bại của một ứng dụng. Groq giải quyết cả hai.

⚡ Tối ưu tốc độ

Chatbot phản hồi tức thì, nâng cao trải nghiệm người dùng

💰 Tiết kiệm chi phí

Free tier đủ để thử nghiệm, production tier rẻ hơn OpenAI

🎓 Dễ bắt đầu

API tương tự OpenAI, chỉ cần đổi 2 dòng code



Groq Giải Quyết Vấn Đề Như Thế Nào?

Với chip **LPU (Language Processing Unit)** chuyên biệt, Groq đạt tốc độ **nhANH gấp 10–100 lần** so với GPU thông thường trong các tác vụ inference LLM.

Trước

GPU: inference 5–10s, tốn kém, độ trễ cao

Sau

Groq LPU: <100ms, chi phí thấp, tích hợp Langchain



🔌 **Tích hợp với Langchain:** Chỉ cần thay ChatOpenAI bằng ChatGroq — toàn bộ logic chains, memory và retrieval hoạt động nguyên vẹn.

⚡ **Kết quả thực tế:** Trong **Chatbots Groq**, chatbot phản hồi gần như tức thì, tạo trải nghiệm hội thoại tự nhiên và mượt mà.

respon



Cơ Chế Hoạt Động Qua API

Groq hoạt động như một **cloud API** hoàn toàn tương thích với chuẩn OpenAI — bạn gửi prompt, Groq xử lý trên LPU và trả về kết quả trong **dưới 100ms**.

Thiết lập trong code

01

Cấu hình API Key

GROQ_API_KEY từ biến môi trường .env

02

Khởi tạo ChatGroq

ChatGroq(model="gemma2-9b-it")
hoặc Llama

03

Invoke như LLM thông thường


model.invoke(messages) — tương
thích hoàn toàn

Ưu điểm API approach

- Không cần cài đặt phần cứng hay driver phức tạp
- Scale tự động theo nhu cầu sử dụng
- Free tier với giới hạn requests hào phóng cho học tập
- Hỗ trợ nhiều mô hình: Llama 3, Gemma 2, Mixtral



LLAMA 3


Gemma

 **MISTRAL
AI_**

r app

Ứng Dụng Thực Tế: Chatbot Real Time



Trải nghiệm phản hồi tức thì

Kết hợp Langchain (quản lý logic, memory, chains) với Groq (tốc độ xử lý), chatbot trong dự án **Chatbots Groq** đạt được trải nghiệm hội thoại gần như tức thì — điều gần như không thể với GPU thông thường.



Ngân hàng

Tư vấn sản phẩm, kiểm tra số dư tức thì



E-commerce

Hỗ trợ đơn hàng, theo dõi vận chuyển



Giáo dục

Gia sư AI giải đáp câu hỏi học sinh

Ứng Dụng Thực Tế: Tóm Tắt & Q&A Tốc Độ Cao

Tóm tắt nhanh với dự án Youtube Summarization

Groq xử lý transcript video YouTube dài hàng nghìn từ trong vài giây thay vì vài phút. Hàm `summarize_docs()` trong **dự án** tận dụng tốc độ Groq để tóm tắt ngay lập tức, lý tưởng cho giáo dục và nghiên cứu.

Q&A chatbot với Conversation QA

Hệ thống hỏi đáp kết hợp retrieval + Groq phản hồi tức thì, hỗ trợ nhiều câu hỏi liên tiếp mà không có độ trễ đáng kể. Lý tưởng cho tra cứu tài liệu nội bộ doanh nghiệp hay cổng thông tin học thuật.

Transcript with Gemini AI

JavaScript runtime built on Chrom

Ứng Dụng Trong Các Lĩnh Vực Lớn

Khả năng xử lý tốc độ cao và chi phí thấp của Groq mở ra cơ hội ứng dụng AI trong nhiều ngành công nghiệp vốn đòi hỏi **phản hồi real-time**.




Gaming

NPC (Non-Player Character) hội thoại thông minh và tự nhiên trong game, phản hồi tức thì mà không gián đoạn gameplay.



Y Tế

Tư vấn triệu chứng ban đầu, hỗ trợ chẩn đoán sơ bộ tức thì, giảm tải cho nhân viên y tế tuyến đầu.



IoT & Edge

Thiết bị thông minh phản hồi lệnh ngôn ngữ tự nhiên ngay lập tức, tối ưu chi phí so với AWS/GCP truyền thống.

Langchain & Groq: Sức Mạnh Kết Hợp

Langchain — Framework Tích Hợp

- Kết nối LLM với hệ thống thực tế
- Chains, Memory, Retrieval, Agents
- Mã nguồn mở, cộng đồng lớn
- Từ prototype đến production

Groq — Backend Tốc Độ Cao

- Chip LPU chuyên biệt cho inference
- Phản hồi dưới 100ms thực tế
- API dễ tích hợp, free tier hào phóng
- Lý tưởng cho real-time applications



Tổng kết: Langchain cung cấp *trí thông minh cấu trúc* — Groq cung cấp *tốc độ thực thi*. Kết hợp hai yếu tố này, bạn có đầy đủ công cụ để xây dựng ứng dụng AI sẵn sàng đưa vào sản xuất thực tế.

Ứng Dụng Tổng Hợp & Lợi Ích Thực Tiễn

Từ dự án khoá học đến Sản Phẩm Thực Tế

Toàn bộ kiến thức trong các dự án thực hành đều có thể triển khai trực tiếp vào sản phẩm thực tế. Sự kết hợp Langchain + Groq đem lại lợi thế rõ ràng cho bất kỳ ai muốn xây dựng ứng dụng AI.

1

Dễ triển khai

Từ ý tưởng đến prototype trong vài giờ với code sẵn có từ notebook

2

Tối ưu chi phí

Groq free tier + Langchain open-source = chi phí thử nghiệm gần như bằng 0

3

Mở rộng dễ dàng

Từ chatbot đơn giản đến hệ thống RAG phức tạp, cùng một framework

